



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
DEPARTAMENTO DE CIÊNCIAS ATMOSFÉRICAS E CLIMÁTICAS

CURSO: METEOROLOGIA
CLIMATOLOGIA ESTATÍSTICA III
PROFESSOR: PAULO SÉRGIO LÚCIO
QUINTO PERÍODO



UNIDADE 2
VITÓRIA RÉGIA SILVA DE SOUZA


ATIVIDADE

NATAL - RN
2023

```

> PAISES <- read.csv("C:/Users/NESC/Downloads/tempventos1 - Página1.csv")
> View(PAISES)
> #Determinar n° de grupos (centróides) avaliar a variância e a quantidade
de grupos
> #via gráfico
> wss <- (nrow(PAISES)-1)*sum(apply(PAISES[-1],2,var))
> for (i in 1:14) wss[i] <- sum(kmeans(PAISES[-1],
+                                centers=i)$withinss) # variabilidade
cte (variabilidade dentro < que entre os grupos)
> plot(1:14, wss, type="b", xlab="Número de grupos",
+      ylab="Soma de quadrados dentro do grupo") # gráfico mostra a
quantidade de grupos e suas respectivas variâncias

```



```

> # _____
> #AGRUPAMENTO NÃO HIERÁRQUICO
> # _____
> # K-Médias Análise de agrupamentos
> fit <- kmeans(PAISES[-1], 5) # Solução com 5 grupos
> #Obter médias dos grupos
> aggregate(PAISES[-1],by=list(fit$cluster),FUN=mean)#incrementa a
localização dos elementos nos grupos no banco de dados inicial
  Group.1 tempmax tempmin vento
1      1 30.78571 23.67143 1.776757
2      2 27.20000 23.30000 1.187500
3      3 31.50000 22.70000 1.166600
4      4 30.42000 24.68000 2.186180
5      5 32.80000 24.20000 1.812500
> # localização dos elementos nos grupos
> (PAISES <- data.frame(PAISES[-1], fit$cluster)) #substitui o dendograma
  tempmax tempmin vento fit.cluster
1    27.2    23.3 1.1875           2
2    30.2    23.3 1.5375           1

```


3	30.5	23.7	1.7583	1
4	30.4	25.2	2.2250	4
5	30.9	24.0	1.8583	1
6	30.9	23.8	1.7916	1
7	31.4	23.9	1.6625	1
8	30.7	24.4	1.8750	4
9	31.1	23.8	1.8083	1
10	30.1	24.7	2.1434	4
11	30.5	24.4	2.2250	4
12	30.5	23.2	2.0208	1
13	30.4	24.7	2.4625	4
14	32.8	24.2	1.8125	5
15	31.5	22.7	1.1666	3

```

> names(fit)
[1] "cluster"      "centers"      "totss"        "withinss"
"tot.withinss" "betweenss"    "size"         "iter"         "ifault"
> #
> # Agrupamento hierárquico via método de Ward
> #
> d <- dist(PAISES[-1], method = "euclidean") # matriz de distâncias
> fit <- hclust(d, method="ward.D2")
> #?dist
> plot(fit,xlab="Distância",main="Dendograma") # Gráfico dendograma

```

Dendograma



Distância
hclust (*, "ward.D2")

```

> grupos <- cutree(fit, k=5) # cortar árvore em cinco grupos
> rect.hclust(fit, k=5, border=2) #Dendogrma com bordas vermelhas ao redor dos 5 grupos
> grupos <- cutree(fit, k=5) # cortar árvore em cinco grupos
> rect.hclust(fit, k=5, border=2) #Dendogrma com bordas vermelhas ao redor dos 5 grupos
> # Agrupamento hierárquico via método de Ward


```

```

> #com p valores via simulação bootstrap
> library(pvclust)
Warning message:
package 'pvclust' was built under R version 4.2.3
> fit <- pvclust(PAISES[-1], method.hclust="ward.D2",
+               method.dist="euclidean")
Bootstrap (r = 0.47)... Done.
Bootstrap (r = 0.6)... Done.
Bootstrap (r = 0.67)... Done.
Bootstrap (r = 0.8)... Done.
Bootstrap (r = 0.87)... Done.
Bootstrap (r = 1.0)... Done.
Bootstrap (r = 1.07)... Done.
Bootstrap (r = 1.2)... Done.
Bootstrap (r = 1.27)... Done.
Bootstrap (r = 1.4)... Done.
> plot(fit) # dendrograma com p valores

```


Cluster dendrogram with p-values (%)



```

> #adiciona retângulos em torno dos grupos
> pvrect(fit, alpha=.95) #

```



```
> # _____
> #nomear os ramos das árvores
> # _____
> str(PAISES)
'data.frame':   15 obs. of  4 variables:
 $ tempmax      : num  27.2 30.2 30.5 30.4 30.9 30.9 31.4 30.7 31.1 30.1 ...
 $ tempmin      : num  23.3 23.3 23.7 25.2 24 23.8 23.9 24.4 23.8 24.7 ...
 $ vento        : num   1.19 1.54 1.76 2.23 1.86 ...
 $ fit.cluster: int   2 1 1 4 1 1 1 4 1 4 ...
> x<-PAISES[,2:4]
> rownames(x)<-PAISES[,1]
Error in `.rowNamesDF<-(x, value = value)` :
  'row.names' duplicados não são permitidos
In addition: Warning message:
non-unique values when setting 'row.names': '30.4', '30.5', '30.9'
> #####ABORDAGEM ALTERNATIVA PARA
rownames(x)<-PAISES[,1]
> nomes_linha <- paste0("linha_", seq_len(nrow(x))) # Gera nomes de linha
únicos com base em um número sequencial
> rownames(x) <- nomes_linha
> #####
> distancias<-dist(x)
> (hc.obj.comp<-hclust(distancias))

Call:
hclust(d = distancias)
```

```

Cluster method      : complete
Distance            : euclidean
Number of objects: 15
> #gráfico
> plot(hc.obj.comp)
> rect.hclust(hc.obj.comp, k=5, border=2)

```



```
> library(mclust)
```



version 6.0.0

Type 'citation("mclust")' for citing this R package in publications.

Warning message:

package 'mclust' was built under R version 4.2.3

```
> fit <- Mclust(PAISES[-1])
```

fitting ...

```

=====
=====

```

100%

```
> plot(fit,xlab="Distância",main="Dendograma") # gráfico dos valores
ajustados
```

Model-based clustering plots:

1: BIC

2: classification

3: uncertainty

4: density

Selection: summary(fit) # mostra o melhor modelo

Enter an item from the menu, or 0 to exit

Selection: 0


```
> # as K-Médias dos 5 grupos
```

```
> fit <- kmeans(PAISES[-1], 5)
```

```
> # obter um melhor gráfico variando os parâmetros
```

```
> library(cluster)
```


```
> clusplot(PAISES[-1], fit$cluster, color=TRUE, shade=TRUE, labels=2,
lines=0,xlab="Componente 1",ylab="Componente 2",main="Indice de
Desenvolvimento ")
```



```
> # Gráfico de agrupamento utilizando 2 funções discriminantes
```

```
> library(fpc)
```

```
> plotcluster(PAISES[-1], fit$cluster,xlab="Discriminante
1",ylab="Discriminante 2")
```



```
> #Coparando dois grupos
> library(fpc)
> cluster.stats(d, fit1$cluster, fit2$cluster)
Error in cluster.stats(d, fit1$cluster, fit2$cluster) :
  object 'fit1' not found
> View(d)
> d

> d
      1      2      3      4      5      6      7      8      9     10     11     12     13     14
2 1.0594810
3 1.2189391 0.4568946
4 2.9472710 3.6169955 3.3864153
5 1.3928290 0.7700082 0.3162278 3.2518408
6 1.2708016 0.5608626 0.1053987 3.3388375 0.2108291
7 1.2592160 0.6128825 0.2217603 3.3175904 0.2198582 0.1632998
8 2.3838323 3.2130836 3.0827940 0.8732125 3.0265953 3.0605482 3.0487959
9 1.2788247 0.5686235 0.1118034 3.3367108 0.2061553 0.0167000 0.1767983 3.0601387
10 2.6217828 3.3655779 3.1856400 0.5066148 3.0937489 3.1517873 3.1418569 0.4025401 3.1499670
11 2.5072707 3.2684333 3.1157357 0.8000000 3.0486831 3.0899572 3.0929608 0.3500000 3.0876591 0.3108996
12 1.3055225 0.4935371 0.5647178 3.6113291 0.8163371 0.6422870 0.7863707 3.2343867 0.6365189 3.3563419 3.2375450
13 2.7542013 3.4373864 3.2397373 0.5535397 3.1392766 3.2031401 3.2062439 0.6596637 3.1996840 0.3191000 0.3826307 3.3830606
14 3.1938417 4.1092122 4.0314932 1.4731450 4.0052587 4.0200046 4.0140379 1.0217173 4.0199524 1.1659738 1.1000710 4.1283639 1.2932517
15 1.1663776 2.1207468 2.3130302 2.8931316 2.4836362 2.3665640 2.3845161 2.0956695 2.3710291 2.4401103 2.2383500 2.2315147 2.5844452 2.5820896

> #Coparando dois grupos
> library(fpc)
> cluster.stats(d, fit1$cluster, fit2$cluster)
Error in cluster.stats(d, fit1$cluster, fit2$cluster) :
  object 'fit1' not found
> cluster.stats(d, fit$cluster)
$ n
[1] 15

$ cluster.number
[1] 5

$ cluster.size
[1] 1 7 2 1 4
```


\$min.cluster.size

[1] 1

\$noisen

[1] 0

\$diameter

[1] NA 0.8163371 1.1663776 NA 0.6596637

\$average.distance

[1] NaN 0.4122796 1.1663776 NaN 0.4041390

\$median.distance

[1] NA 0.4568946 1.1663776 NA 0.3663153

\$separation

[1] 1.0217173 1.0594810 1.0594810 0.5066148 0.5066148

\$average.toother

[1] 2.868458 2.967240 2.165333 2.421902 2.633200

\$separation.matrix

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	0.000000	4.005259	2.582090	1.4731450	1.0217173
[2,]	4.005259	0.000000	1.059481	3.2518408	3.0265953
[3,]	2.582090	1.059481	0.000000	2.8931316	2.0956695
[4,]	1.473145	3.251841	2.893132	0.0000000	0.5066148
[5,]	1.021717	3.026595	2.095669	0.5066148	0.0000000

\$ave.between.matrix

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	0.000000	4.046903	2.887966	1.4731450	1.1452535
[2,]	4.046903	0.000000	1.789761	3.4085313	3.1757416
[3,]	2.887966	1.789761	0.000000	2.9202013	2.4532077
[4,]	1.473145	3.408531	2.920201	0.0000000	0.6833418
[5,]	1.145253	3.175742	2.453208	0.6833418	0.0000000

\$average.between

[1] 2.677857

\$average.within

[1] 0.5257899

\$n.between

[1] 77

\$n.within

[1] 28

\$max.diameter

[1] 1.166378

```
$min.separation  
[1] 0.5066148
```

```
$within.cluster.ss  
[1] 1.638711
```

```
$clus.avg.silwidths  
      1      2      3      4      5  
0.0000000 0.7668124 0.2844452 0.0000000 0.3817322
```

```
$avg.silwidth  
[1] 0.4975671
```

```
$g2  
NULL
```

```
$g3  
NULL
```

```
$pearsongamma  
[1] 0.7730762
```

```
$dunn  
[1] 0.4343489
```

```
$dunn2  
[1] 0.5858666
```

```
$entropy  
[1] 1.337861
```

```
$wb.ratio  
[1] 0.1963473
```

```
$ch  
[1] 61.25995
```

```
$cwidegap  
[1] 0.0000000 0.4935371 1.1663776 0.0000000 0.3500000
```

```
$widestgap  
[1] 1.166378
```

```
$sindex  
[1] 0.5066148
```

```
$corrected.rand  
NULL
```

```
$vi  
NULL
```

```

> #
> #UTILIZANDO OUTRO TUTORIAL
> #
> #EXPLORAÇÃO DOS DADOS
> #CORRELAÇÃO
> cor(PAISES[-1])
      tempmin      vento fit.cluster
tempmin      1.0000000 0.8087555   0.6016159
vento         0.8087555 1.0000000   0.4053896
fit.cluster   0.6016159 0.4053896   1.0000000
> #Técnica Hierárquica Aglomerativa
> # Calculo da matriz de distâncias
> d = dist(PAISES[-1], method = "euclidean")
> min(d) #menor distância da matriz
[1] 0.0167
> fit = hclust(d, method="complete")
> # Dendrograma do agrupamento
> plot(fit,main="Dendrograma",ylab="Distância",sub="Função de ligação
Completa")
> rect.hclust(fit, k=4, border=2:5) # circula 3 os grupos
> wss <- (nrow(PAISES[-1])-1)*sum(apply(PAISES[-1],2,var))#soma de quadrado
total
> for (i in 1:14) wss[i] <- sum(kmeans(PAISES[-1],
+                                centers=i)$withinss)#somas de
quadrados, há uma parte aleatória devido ao centers
> t=kmeans(PAISES[-1], centers=5)
> plot(1:14, wss, type="b", xlab="Número de Clusters",
+      ylab="Soma de quadrados dentro dos grupos")

```

